

- 一、MMAR-Rubrics的评测方式
- 二、实验设计和结果
 - 2.1 证明MMAR-Rubrics的instance-level比general-system-level的评测基线优秀
 - 2.1.1 实验结果
 - 2.1.2 Inter-rater 和 Intra-rater
 - 2.1.3 Human Alognment
 - 2.1.4 结论
 - 2.1.5 数学知识补贴: Krippendorff's Alpha
 - 2.1.5.1 数学定义
 - 2.1.5.2 例子1
 - 2.1.5.4 例子2
 - 2.2 single-model track & agent track的结果
 - 2.2.1 各自track前3名的具体信息
 - 2.2.2 结论
- 三、总结

为了防止MMAR只基于结果的二值评分（0 or 1）现象的出现，MMAR-Rubris给每个MMAR的task都加上了结合具体题目场景的对cot进行打分的rubrics。每题的rubrics是由Gemini-2.5-Pro生成的。

一、MMAR-Rubrics的评测方式

设置明确的rubrics来帮助llm客观的评分：

Q: Estimate the depth of the well based on the sound heard when a stone is thrown at the moment a person starts speaking. 0-100m 100-200m 200-300m 300-400m	
The key to estimating the depth of the well lies in analyzing the time delay between the moment the stone is dropped and the moment the echo is heard. This time delay, combined with the speed of sound, allows for a calculation of depth using the formula: $\text{Distance} = (\text{Speed of Sound} \times \text{Time Delay}) / 2$. From the audio, the echo has a significant delay, estimated to be between 2 and 2.5 seconds. This timing places the depth in the 200–300 meter range. Other acoustic cues, like the sharp reverberation and lack of multiple echoes, support a deep, well-like structure, ruling out shallower options where the echo would be too fast, or deeper options which would likely produce a longer delay.	C1: The test-taker correctly identifies the echo and splash sound as key auditory cues in the audio recording. C2: The test-taker correctly identifies the time interval between the action (stone thrown) and the echo return (eight seconds) as critical for the calculation. C3: The test-taker recognizes and applies the free-fall formula ($H = 1/2 g T_1^2$) to determine the stone's travel time and correlate it with well depth. C4: The test-taker correctly applies the speed of sound (340 m/s) to calculate T_2 and integrate it into the depth computation. C5: The test-taker combines the free-fall formula and sound-speed equation to solve for H and accurately selects the correct depth range (200-300m).
Predicted Reasoning Path	Rubric score: 0.4

Figure 1: An example of how MMAR-Rubrics evaluate a reasoning process.

具体评分规则：

有输入audio A,query Q：

$$(\hat{Y}_{cot}, \hat{Y}_{answer}) = F(A, Q)$$

得分规则为：

$$S = \begin{cases} \mathcal{E}(\hat{Y}_{CoT}) & \text{if } \hat{Y}_{Answer} = Y_{Answer} \\ 0 & \text{if } \hat{Y}_{Answer} \neq Y_{Answer} \end{cases}$$

一个task有k个criteria，则：

$$\mathcal{E}(\hat{Y}_{cot}) = \frac{1}{k} \sum_{i=1}^k \mathbb{I}(\text{criterion}_i \text{ is satisfied})$$

评测支持两个track,一个single-model track,一个agent track。

二、实验设计和结果

2.1 证明MMAR-Rubrics的instance-level比general-system-level的评测基线优秀

2.1.1 实验结果

Table 1: *Comparison between system-level and instance-level evaluation protocols. Reliability is measured by Krippendorff's alpha (α). Inter-rater reliability is calculated across three LLM raters (M_1 : GPT-4o, M_2 : Gemini-2.5-Flash, M_3 : GPT-5-mini). Intra-rater reliability is calculated across five runs of M_1 . Human Alignment is measured against 50 pairs of human-preferred (C) and rejected (R) reasoning path. The columns show the counts of how many times the LLM rater (M_1) agreed with the human preference ($C > R$), disagreed ($C < R$), or judged the responses as equal ($C = R$).*

Protocol	Reliability ($\alpha \uparrow$)		Human Alignment		
	Inter-rater	Intra-rater	$C > R \uparrow$	$C < R \downarrow$	$C = R$
System-level	0.7459	0.9081	15	8	27
Instance-level	0.7921	0.9216	17	2	31

2.1.2 Inter-rater 和 Intra-rater

Inter-rater (组间一致性)：

测试方式：找 3 个完全不同的 AI 裁判（GPT-4o、Gemini-2.5-Flash、GPT-5-mini）给相同的 664 条推理路径打分。
目的：看不同模型之间的标准合不合，避免某种特定模型产生偏见。

Intra-rater (评分者内一致性 / 自身稳定性)：

测试方式：让同一个 AI 裁判（GPT-4o，在温度设为 Temperature = 1.0 的随机状态下）连续跑 5 次。
目的：看模型自己打分稳不稳定。

2.1.3 Human Alognment

研究者抽取了 50 对回答（每对包含人类认可的回答 C 和人类拒绝的坏回答 R ）：

$C > R \uparrow$ （看对）：AI 打分也认为好回答 C 高于坏回答 R （越高越好）。

$C < R \downarrow$ （偏好倒置 / 判反了）：AI 竟然觉得坏回答 R 比好回答 C 还好，属于致命的判定错误（越低越好）。

$C = R$ ：AI 觉得两者差不多（打平）。

2.1.4 结论

作者提出的 Instance-level (MMAR-Rubrics) 相比于旧的 System-level baseline 实现全方位碾压：

- **跨模型打分更统一**：不同模型间的一致性 α 从 0.7459 飙升到 0.7921（逼近 0.8 的黄金线）。
- **自身重测极度稳定**：同一个模型的自身重复测试一致性高达 0.9216。
- **严重低级错误骤降**：把人类喜欢的判成坏的（ $C < R$ 的偏好颠倒）从原来的 8 次直接砍到了 2 次。

2.1.5 数学知识补贴：Krippendorff's Alpha

2.1.5.1 数学定义

这是一个用来测量“多个裁判（评分者）意见到底有多一致”的统计学指标。

直观公式：

$$\alpha = 1 - \frac{D_o}{D_e}$$

D_o (Observed Disagreement)：裁判们打分时实际产生的分歧。

D_e (Expected Disagreement)：假设裁判们完全闭着眼睛瞎猜时，理论上会产生的随机分歧。

数值含义：

$\alpha = 1$ ：所有人意见 100% 完全一致。

$\alpha = 0$ ：大家的打分完全等同于抛硬币瞎猜。

黄金标准：通常 $\alpha \geq 0.8$ 被认为是极度可靠； $\alpha \geq 0.7$ 属于非常优秀的社会学/评估一致性。

2.1.5.2 例子1

假设我们有 2 个样本，请了 3 位裁判 打分（只能打 1 分 表示通过，0 分 表示不通过）：

- **样本 A**：裁判 1 打 1，裁判 2 打 1，裁判 3 打 0
- **样本 B**：裁判 1 打 0，裁判 2 打 0，裁判 3 打 0

样本A：我们可以把 3 个裁判两两组合，形成 3 个配对：

- 裁判 1 (打1) 和 裁判 2 (打1) $\rightarrow$ 打分一样（分歧 = 0）
- 裁判 1 (打1) 和 裁判 3 (打0) $\rightarrow$ 打分不一样（分歧 = 1）
- 裁判 2 (打1) 和 裁判 3 (打0) $\rightarrow$ 打分不一样（分歧 = 1）

一共 3 个配对，有 2 个配对产生分歧。

样本B同样两两组合，形成 3 个配对：

- 裁判 1 (打0) 和 裁判 2 (打0) → 打分一样 (分歧 = 0)
- 裁判 1 (打0) 和 裁判 3 (打0) → 打分一样 (分歧 = 0)
- 裁判 2 (打0) 和 裁判 3 (打0) → 打分一样 (分歧 = 0)

一共 3 个配对，有 0 个配对产生分歧。则全部配对总数 = 样本 A 的 3 对 + 样本 B 的 3 对 = 6 对，发生分歧的配对总数 = 2 + 0 = 2 对

$$D_o = \frac{\text{发生分歧的配对数}}{\text{总配对数}} = \frac{2}{6} = \frac{1}{3} \approx 0.333$$

从上面的样本 A 和 B 里，裁判一共打了 6 个分数：

- 样本 A 出了：[1, 1, 0]
- 样本 B 出了：[0, 0, 0]
- 帽子里的 6 个球：1, 1, 0, 0, 0, 0 (也就是 2 个“1”和 4 个“0”)。

从 6 个球里任意抽取 2 个球，总共有 15 种抽法。

要抽到一个 1 和一个 0：

- 从 2 个 1 里抽 1 个，有 2 种可能；
- 从 4 个 0 里抽 1 个，有 4 种可能；

产生分歧的抽法数 = $2 \times 4 = 8$ 种

则：

$$D_e = \frac{\text{随机抽能产生分歧的种数}}{\text{随机抽的总种数}} = \frac{8}{15} \approx 0.533$$

现在我们有：

- 实际分歧 $D_o = 0.333$
- 瞎猜分歧 $D_e = 0.533$

直接带入公式：

$$\alpha = 1 - \frac{D_o}{D_e} = 1 - \frac{0.333}{0.533} = 1 - 0.625 = 0.375$$

实际分歧比乱猜分歧要小，说明裁判们还是有一定默契的，但 $\alpha = 0.375$ 距离理想值 (≥ 0.8) 还差得很远。

2.1.5.4 例子2

在 MMAR-Rubrics 场景中，虽然底层细则是 0/1 勾选，但汇总给整条推理路径打出来的是 **0.0 ~ 1.0 的连续得分** (如 $2/5 = 0.4$ 分)。此时差异用“数值差的平方” $\delta^2(k, l) = (k - l)^2$ 来度量。

假设让 GPT-4o (裁判 1) 和 Gemini (裁判 2) 对 2 条音频推理路径打分：

- **音频路径 A**：GPT-4o 给了 **0.4 分** (对 2 项)，Gemini 给了 **0.6 分** (对 3 项)
- **音频路径 B**：GPT-4o 给了 **0.8 分** (对 4 项)，Gemini 给了 **0.8 分** (对 4 项)

-
- 路径 A 内配对：打分差的平方为 $(0.4 - 0.6)^2 = (-0.2)^2 = 0.04$
 - 路径 B 内配对：打分差的平方为 $(0.8 - 0.8)^2 = 0^2 = 0.00$

两个样本的平均实际分歧：

$$D_o = \frac{0.04 + 0.00}{2} = 0.02$$

把所有裁判打出的 4 个分数装进帽子：[0.4, 0.6, 0.8, 0.8]。

从这 4 个分数里任意不重复地抽取 2 个，一共有 $\frac{4 \times 3}{2} = 6$ 种可能配对，分别计算它们的平方差：

配对组合	差异平方计算 δ^2	数值
0.4 vs 0.6	$(0.4 - 0.6)^2$	0.04
0.4 vs 0.8 (第一位)	$(0.4 - 0.8)^2$	0.16
0.4 vs 0.8 (第二位)	$(0.4 - 0.8)^2$	0.16
0.6 vs 0.8 (第一位)	$(0.6 - 0.8)^2$	0.04
0.6 vs 0.8 (第二位)	$(0.6 - 0.8)^2$	0.04
0.8 vs 0.8	$(0.8 - 0.8)^2$	0.00

求这 6 种乱抽配对的平均平方差：

$$D_e = \frac{0.04+0.16+0.16+0.04+0.04+0.00}{6} = \frac{0.44}{6} \approx 0.0733$$

则：

$$\alpha = 1 - \frac{D_o}{D_e} = 1 - \frac{0.02}{0.0733} \approx 1 - 0.2728 = \mathbf{0.7272}$$

由于 0.4 与 0.6 相差不大，且路径 B 完美一致，实际平方分歧 $D_o(0.02)$ 远远小于随机瞎猜的期望分歧 $D_e(0.0733)$ ，因此最终计算出两名 AI 裁判的一致性达到了 0.7272 的较高水平。

2.2 single-model track & agent track的结果

2.2.1 各自track前3名的具体信息

Table 2: Solutions of top performing teams in the Audio Reasoning Challenge (Single Model Track).

Rank	Rubrics	Accuracy	Base Model	Post-Training Method
1	65.29	74.00	Qwen3-Omni-Instruct	two-stage RL (GRPO with designed rewards)
2	62.55	71.00	Qwen3-Omni-Thinking	training-free (with attention manipulation)
3	62.22	71.70	Qwen3-Omni-Thinking	LoRA SFT (with sophisticated data pipeline)

Table 3: Solutions of top performing teams in the Audio Reasoning Challenge (Agent Track).

Rank	Rubrics	Accuracy	Soultion	Novelty
1	69.83	0.769	iterative evidence gathering	40+ audio tools integrated
2	66.23	0.774	multi-agent voting	VLM for spectrogram analysis on numerical tasks
3	66.09	0.751	multi-agent debate	multi-agent debate and consensus

Table 4: *Final stage leaderboard of the Audio Reasoning Challenge.* We report the results of teams who submitted results in the final phase across both the Single Model Track and the Agent Track. “Rubrics” denotes the instance-level rubric-based reasoning quality score, and “Acc” denotes the final answer accuracy (%) in MMAR. Note that agent-based systems generally achieved higher reasoning scores.

Rank	Single Model Track		Agent Track	
	Rubrics (%)	Acc (%)	Rubrics (%)	Acc (%)
1	65.29	74.00	69.83	76.90
2	62.55	71.00	66.23	77.40
3	62.22	71.70	66.09	75.10
4	60.61	73.40	64.61	72.20
5	58.86	71.20	63.00	71.00
6	58.53	69.30	62.63	73.60
7	57.77	69.40	62.35	72.60
8	57.15	68.10	61.85	72.70
9	56.03	68.40	60.25	77.10
10	47.83	63.60	59.47	68.20
11	47.49	62.50	57.51	69.80
12	38.93	62.60	54.16	70.50
13	23.77	46.40	53.30	71.70
14	19.03	40.40	53.03	68.60
15	-	-	47.84	65.00
16	-	-	23.91	46.40

2.2.2 结论

Single Model Track:

1. 第一名（渐进式两阶段强化学习）：采用两阶段 RL（基于 GRPO 算法）。第一阶段为在公开 QA 数据上从头训练的“RL-zero”；第二阶段为“边界增强（Boundary Enhancement）”，引入硬负样本与边界样例，利用 CoT 路径的语义相似度作为奖励信号。
2. 第二名（无需训练的注意力机制修改）：基于 Qwen3-Omni-Thinking 模型，在不更新参数的情况下修改 Attention 机制。通过为音频 Token 区域的注意力权重引入缩放因子（Scaling Factor），强制模型对音频线索赋予更高注意力，有效缓解了多模态模型常见的“泛读（Skimming）”现象。
3. 第三名（基于 LoRA 的高质量 SFT）：拒绝传统的 CoT 逆向工程合成数据（因为直接给答案和音频，模型模拟

的COT容易因为被要求硬性推理出答案而出现幻觉)，改用“问题到推理（Question-to-Reasoning）”的标注策略以保障推理路径贴合音频线索；同时搭配双重验证机制，在训练前使用 LLM 作为裁判过滤掉幻觉数据。

Agent Track:

1. 第一名（多工具集成与迭代式证据收集）：构建了一个集成 40+ 专项音频工具（涵盖 ASR、声源分离、说话人日志、频谱特征提取及乐理分析等）的庞大 Agent 系统。核心创新在于**迭代式证据收集循环（Iterative Evidence Gathering Loop）**：当初始置信度较低时，Agent 可以使用不同工具重新查询音频，模拟人类的“主动倾听”。
2. 第二名（跨模态视觉表征与一致性分流）：将音频转换为梅尔频谱（Mel）、CQT 及 RMS 频谱图等视觉图像，利用视觉语言模型（VLM）进行细粒度数值分析（如事件计数、时长测量）；同时结合“一致性分流（Consistency Split）”机制，根据子模型间的一致性将样本路由至不同的求解器。
3. 第三名（多智能体辩论与中央协调）：采用由中央控制器（Controller）统筹的多 Agent 辩论框架。各 Agent 独立生成假设并相互批判、生成“同行意见（Peer Opinions）”，通过多轮推理消除冲突并达成共识，显著降低了幻觉率。

Agent track的两项评分尤其是cot评分普遍比Single model track高，但Single model track整体和Agent track的gap并不大，揭示了Agent系统在处理复杂音频理解和推理任务的本身的优秀性和鲁棒性，以及通过RL或者复杂的数据管线使得模型内化较复杂的cot方案的巨大潜力。

三、总结

为了防止MMAR进行只基于结果的二值评分过于单一，不够准确，MMAR-Rubris给每个MMAR的task都加上了结合具体题目场景的对cot进行打分的rubrics。评测是instance-level的，支持两个track,一个single-model track,一个agent track。经过和system-level的对比实验，证明了这种评测方式的优秀性。single-model track的前三名采用了渐进式两阶段强化学习、无需训练的注意力机制修改、基于 LoRA 的高质量 SFT等方案，agent track的前三名采用了多工具集成与迭代式证据收集、跨模态视觉表征与一致性分流、多智能体辩论与中央协调等方案。Agent track的两项评分尤其是cot评分普遍比Single model track高，但Single model track整体和Agent track的gap并不大，揭示了Agent系统在处理复杂音频理解和推理任务的本身的优秀性和鲁棒性，以及通过RL或者复杂的数据管线使得模型内化较复杂的cot方案的巨大潜力。